视觉 Transformer 计算图上的 NNS 结构路径分解与系统验证

硕士学位论文 · 匿名内容审阅版

本审阅版不含作者、单位、学号或导师信息

摘要

视觉 Transformer（Vision Transformer，ViT）将图像表示为标记序列，并通过多头自注意力、前馈网络和残差连接逐层变换。现有输入归因方法可以显示类别输出依赖哪些像素，内部表示或注意力分析可以显示标记和通道如何响应，但二者之间仍缺少一套面向 ViT 真实计算边、保持输入空间坐标且能够逐项核验的结构表示。本文以神经网络扫描器（Neural Network Scanner，NNS）的学习图像为起点，研究其数学身份、ViT 计算图上的结构路径分解、层深规律及其对有限内部替换的局部近似范围。

本文首先证明：当各层使用当前前向状态下的精确局部雅可比矩阵，且不加入归一化、截断或相关性重分配时，标量 NNS 学习图像等于同一目标的输入乘梯度。该恒等式用于确定研究对象。随后，本文为 ViT 的标记—通道单元、通道聚合目标、注意力头、残差边和类别输出建立统一目标注册；相对于指定计算图与合法计算切面，将注意力微分分为查询、键和值诱导路径，将残差微分分为恒等路径与分支路径。等价线性重参数化反例表明，总输入图可以保持不变而分项发生改变，因而结构分解依赖计算图、切面和参数化。

实验使用两个固定 ImageNet 预训练参数状态 ViT-B/16 与 DeiT-S/16。数值验证包括 5 000 次 NNS 公式回归、76 800 项正向闭合、28 800 项遗漏或重复负控制、6 144 项解析雅可比—向量积检查及 88 个算子方向检查。层深研究以图像为统计单位：五组独立标记—通道抽样的 30 个模型—抽样组—指标组合均复现熵增加、局部性下降和距离增加；查询、键和值路径的总体统计则显示三者具有不同的层深轨迹。多幅度注意力头输出插值表明，四个模型—参照状态组合和 1 600 条图像—参照状态曲线的绝对误差均随幅度单调增加，头间排序相关由小幅干预时的 0.9564 – 0.9810 降至完整替换时的 0.6095 – 0.6856。完整替换任务中，局部路径图与成分效应的关联广泛但并非普遍；在给定参照状态的区域替换中，显式使用实际位移的区域泰勒估计优于仅使用原输入状态的局部图。

本文的新增工作是 NNS 在 ViT 异构内部目标和真实计算边上的统一实现、相对于指定图的路径记账，以及将数学身份、数值正确性、结构规律和有限干预效用分离检验的系统证据。结论适用于本文两个固定模型参数状态、冻结样本与已规定替换算子。

关键词： 视觉 Transformer；神经网络扫描器；学习图像；局部雅可比矩阵；结构路径分解；有限干预

目录

1. 绪论 2. 相关工作 3. NNS 的数学基础与边界 4. ViT 结构路径分解方法 5. 研究设计与统计分析 6. 结构路径的层深规律 7. 有限干预中的局部近似与排序 8. 综合讨论与结论

第 1 章 绪论

1.1 研究背景

视觉 Transformer 将图像划分为图像块，经线性投影后与类别标记共同进入 Transformer 编码器[1-3]。与卷积网络相比，其内部对象更加异构：标记—通道单元描述特定空间位置的响应，注意力矩阵控制标记之间的信息混合，多头输出经投影合并，残差连接又把恒等路径与非线性分支叠加。类别预测由这些对象共同形成，仅查看末层注意力权重或一张输入显著图，很难区分局部响应经过了哪些真实计算边。

NNS 为网络内部神经元生成保留输入位置的学习图像[4]。在全连接网络和卷积网络中，这一表示可以沿层传播局部尺度。本文以这一已有输入归因对象为基础，回答三个结构问题：不同内部目标如何映射回统一输入坐标；查询、键、值、注意力头和残差分支如何在不遗漏或重复的条件下分解；局部微分图在多大范围内能够近似有限内部替换。

本研究据此把“表示—贡献—干预”组织为一条证据链。表示层先明确学习图像的数学对象；贡献层在指定计算图上构造可加的路径分项；干预层再用真实内部替换检验这些局部量的适用范围。数值闭合检验实现正确性，真实替换评价有限效应。

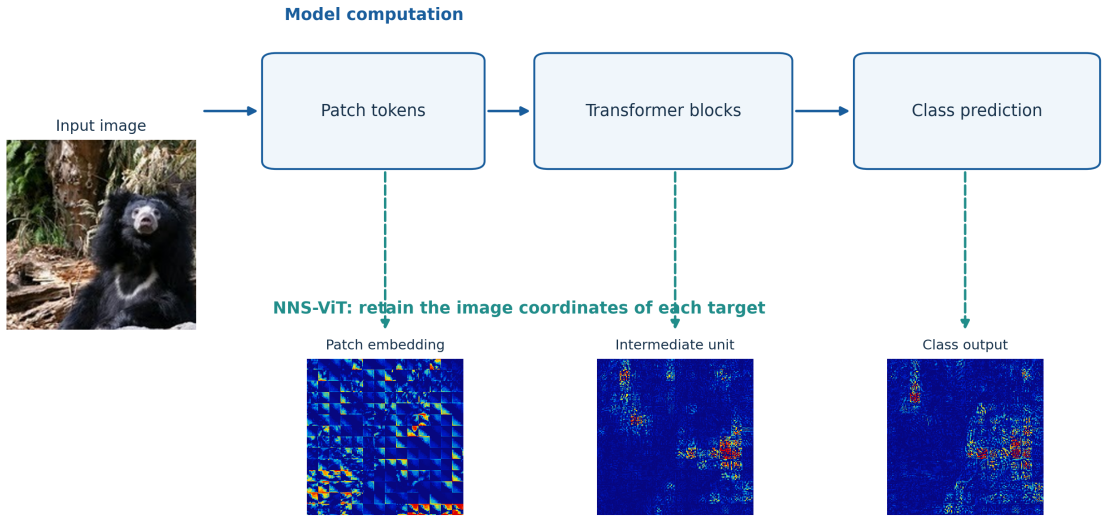


图 1-1 NNS – ViT 研究框架。 正常前向计算产生预测；注册的内部或输出标量目标分别对应输入坐标上的学习图像。

1.2 研究问题

本文研究以下四个研究问题（research question，RQ）。

1. RQ1：NNS 学习图像的数学本质和适用边界是什么？ 研究逐层局部尺度传播与雅可比链式法则、输入乘梯度、输入坐标原点和函数值完整性的关系。

2. RQ2：如何在 ViT 的指定计算图上构造结构路径图？ 研究异构目标注册、合法计算切面、查询/键/值、注意力头和残差路径的定义、闭合及非唯一性。

3. RQ3：结构路径在两个固定预训练参数状态中呈现怎样的层深规律？ 研究抽样单元的空间范围、查询/键/值路径、路由/取值路径及残差恒等/分支路径，并通过独立抽样和参数状态对照评价结论边界。

4. RQ4：局部路径量在规定有限替换中的适用范围是什么？ 研究注意力头输出从原状态向参照状态插值时的一阶误差随幅度变化，以及完整替换任务中的成分排序与区域选择。

四个问题依次对应数学身份、结构表示、经验规律和任务效用。RQ1 与 RQ2 建立方法和正确性，RQ3 与 RQ4 分别评价经验规律和任务效用。

四个问题并非同一层级的平行假设。RQ1 是定义与数学识别问题，作用是确定后续计算的对象；RQ2 是构造与正确性问题，作用是把这一对象分配到 ViT 的真实结构边；RQ3 是描述性经验问题，研究在固定模型和抽样目标上出现的层深规律；RQ4 是有限任务效用问题，评价局部量离开当前点后还能保留多少数值和排序信息。前两问提供后两问的测量基础，后两问则不反向改变前两问的数学定义。

这种层级关系也决定证据强度。恒等式由推导和数值回归支持，结构分解由合法切面条件与闭合负控制支持，层深规律由图像级区间和独立目标抽样支持，有限效用由真实替换支持。论文在每个层级使用相应证据，避免以公式正确代替经验普遍性，或以可视化案例代替干预结果。

1.3 研究内容与技术路线

研究首先将 NNS 写为有向无环计算图上的雅可比传播，得到标量目标的输入乘梯度形式。随后在冻结 ViT 实现中注册目标与真实边，构造查询、键、值、注意力头、恒等路径和分支路径的切面分解。正确性通过公式回归、闭合、负控制、解析雅可比—向量积和有限差分共同核验。

在经验部分，研究分别考察内部单元、注意力和残差。层深统计使用绝对质量、空间熵、局部性、归一化距离、抵消率、相对尺度和近似误差。有限干预使用两类参照状态：归一化零输入和模糊输入；评价对象包括注意力头输出插值、完整成分替换和固定面积的区域替换。所有总体区间先在图内聚合，再以图像为统计单位计算。

技术路线分为四个阶段。第一阶段完成数学对象审计，把原始逐层尺度传播逐算子映射到雅可比链式法则，并保留非光滑点的实际导数选择。第二阶段完成结构实现，以目标注册表统一不同张量形状，以真实使用边而非张量名称定义切面，并用遗漏和重复路径构造负控制。第三阶段完成总体描述，在预先固定的图像、标记、通道和类别目标上计算空间及路径统计。第四阶段完成有限替换，把局部微分、参照位移和真实效应置于同一估计框架，分别研究幅度误差和排序任务。

每个阶段都保留原始数组、汇总表和验证收据。该组织使错误可以定位到对象定义、计算图记账、数值实现或统计解释中的具体一层，而不会把环境与实现问题混入科学结论。

1.4 主要贡献

本文的贡献由已有基础、本文增量和直接证据共同界定。

1. NNS、输入乘梯度与隐藏单元路径归因已经分别提供学习图像、当前点输入加权梯度和参照路径上的内部归因[4,6-9]。本文为 ViT 标记—通道单元、通道聚合、注意力头、残差边和类别目标建立统一目标注册及输入坐标实现。直接证据包括 ViT-B/16 的 457 个和 DeiT-S/16 的 385 个每图注册标量目标、5 000 次公式回归和 88 项算子方向检查。 2. GlobEnc、DecompX、AttnLRP 与 LibraGrad 已经研究 Transformer 的标记贡献或相关性传播[26,28-30]。本文在实际局部雅可比矩阵不变的前提下，对指定 ViT 计算图上的查询、键、值、多头及残差真实边进行合法切面记账。直接证据包括 76 800 项正向闭合、28 800 项负控制和 6 144 项解析方向检查。 3. 激活替换与边归因研究有限内部效应及其一阶近似[31-34]。本文在两个固定 ViT 参数状态上，将结构层深统计、五组独立目标抽样、多幅度插值和完整替换排序纳入同一研究设计，分别报告正确性、描述性规律和有限干预效用。

输入乘梯度恒等式和链式法则界定研究对象；本文的理论与经验增量从面向冻结 ViT 实现的目标注册、切面定义、真实边记账与系统评价开始。

1.5 论文结构

第 2 章梳理输入归因、Transformer 解释和内部干预研究；第 3 章推导 NNS 的数学身份及边界；第 4 章给出 ViT 结构路径方法、闭合命题与非唯一性反例；第 5 章说明样本、模型、估计量与统计分析；第 6 章报告结构路径的层深规律；第 7 章报告多幅度和完整替换结果；第 8 章综合讨论贡献、局限与结论。

1.6 本章小结

本章把研究对象限定为 ViT 指定计算图上的局部输入依赖及其结构分项，并提出从数学身份到有限干预的四个研究问题。本文不以基础公式的新名称建立创新，而以结构实现、图相对分解和分层验证构成研究主线。

第 2 章 相关工作

2.1 输入梯度、路径归因与完整性

输入梯度直接刻画输出对输入的局部敏感性[5]；输入乘梯度将当前输入坐标与梯度逐元素相乘[6,11]。积分梯度（Integrated Gradients）沿参照输入到当前输入的路径平均梯度，并在相应条件下满足完整性公理[7]。DeepLIFT 传播相对于参照激活的贡献差[6]，传导度（conductance）将路径积分扩展到隐藏单元[8]。FullGrad 将输入梯度项与各层偏置—梯度项共同组成函数值完整表示[9]；逐层相关性传播和梯度平滑则提供不同的反向分配与降噪策略[10,12]。

这些方法的差别首先在于解释对象。当前点输入乘梯度是局部量；路径积分和 DeepLIFT 依赖参照状态；FullGrad 的完整性对象包含偏置项。本文研究合法计算切面上局部输入微分的闭合，不把它等同于函数值分解或参照路径完整性。

“ 完整性 ”在这些文献中不是单一概念。Integrated Gradients 的完整性是沿输入路径的归因和等于输出差；FullGrad 的完整性把输入与偏置项共同纳入表示；逐层相关性传播强调相关性守恒。本文的闭合只要求同一局部输入微分在合法切面上不重不漏。比较方法时必须先对齐被加和的对象，否则相同的“ 完整 ”字样会掩盖不同等式。

当前点方法与路径方法还具有不同信息预算。输入乘梯度只需要当前输入及其梯度，Integrated Gradients 和 conductance 需要参照状态及路径上的多个梯度。前者计算直接、适合分析局部结构；后者可以吸收沿路径变化的非线性。第 7 章把这一差别转化为多幅度实验，而不是仅依赖方法定义推断优劣。

2.2 可视化、扰动评价与可靠性检验

Grad-CAM 使用梯度加权卷积特征图产生类别相关区域[13]，反卷积和遮挡研究则从中间特征或输入扰动观察响应[14]。LIME 与 SHAP 从局部代理模型和博弈分摊角度解释预测[15-16]。不同方法可以产生外观相似的热图，却不必共享同一统计对象。参数随机化检验、删除和保留基准及反向传播规则审计表明，视觉可读性不能单独证明解释忠实性[17-20]。

本文因此区分展示与统计。蓝底学习图像仅用于读取空间结构；所有结论从原始带符号数组、绝对质量或真实有限替换中计算。参数状态对照用于判断结果是否依赖训练参数状态，不将单个预训练模型与随机初始化的差异解释为训练因果效应。

显著图可靠性至少包含三类要求。第一类是参数敏感性：模型参数改变时解释应当在相应对象上发生可测变化[17,19]。第二类是任务关联：排序较高的位置在规定删除、保留或替换任务中应产生相应效应[18]。第三类是数值与实现稳定性：结果不能主要由可视化归一化、插值或反向规则的偶然选择决定。本文分别用参数状态对照、有限内部替换和原始数组复算对应这三类要求。

这些要求也说明案例图的角色。案例图可揭示路径在像素空间中的形态，并帮助发现实现错误或值得检验的模式；总体主张则必须由完整样本上的预定统计支持。因而本文的示例选择以可读性为目的，样本选择不会进入效应量和区间计算。

2.3 Transformer 与 ViT 解释

注意力流和注意力展开将跨层注意力矩阵组合为标记间传播图[21]。Chefer 等将相关性传播扩展到 Transformer 的注意力和跳跃连接[22]。与此同时，“ 注意力即解释 ”的充分性受到反例和干预研究的质疑[23-24]；向量范数也会改变仅凭注意力权重得到的贡献判断[25]。

GlobEnc 把整个编码器层纳入标记贡献传播[26]；ALTI 分析上下文信息混合[27]；DecompX 将标记表示分量传播到预测[28]；AttnLRP 和 LibraGrad 分别从相关性守恒和反向梯度平衡构造 Transformer 归因[29-30]。这些工作解决标记贡献、相关性或输入归因。本文保持模型的实际局部导

数，研究同一局部输入微分如何沿指定真实计算边分组。

Transformer 解释还需要区分“ 前向混合 ”与“ 目标条件化依赖 ”。注意力权重和 ALTI 类量主要从前向信息混合描述标记关系；类别相关梯度和相关性方法将下游目标纳入反向传播。同一注意力头可以在前向中具有尖锐权重，却因下游余切较小而对某个类别目标产生较小局部路径。本文把输出投影及目标之后的导数纳入每个头的余切，正是为了保持这一目标条件化语义。

标记贡献与输入像素依赖也不是相同分辨率的对象。前者通常在 14×14 图像块网格或标记序列上定义；后者还经过图像块投影权重映射到像素坐标。本文同时报告原生像素图和图像块统计，并把显示插值排除在数值分析之外，使空间分辨率差异不会被误写成方法优越性。

2.4 内部表示、激活替换与边归因

对内部神经元和前馈层的研究揭示了表示单元与模型行为之间的联系[8,35]。激活替换将原输入状态下的内部变量替换为参照输入产生的变量，并测量输出变化[31]；因果追踪将这一操作用于定位事实关联[34]。归因替换（attribution patching）和边归因替换（edge attribution patching）用激活位移与局部梯度的内积近似有限替换效应[32]，AtP* 进一步处理注意力饱和与抵消[33]。

这类方法直接涉及有限效应，但结果取决于参照状态、被替换变量、替换算子和输出目标。本文分别保留原输入局部图、参照状态感知的泰勒量和真实替换效应，并在多幅度插值中观察一阶误差随距离的变化。

激活替换中的“ 因果 ”是对计算图变量实施规定操作后的模型内效应。替换单个头而保持其他头和恒等路径为原状态，会形成一个混合前向状态；它回答该操作对目标逻辑值的影响，而不是自然图像区域在数据生成过程中的因果效应。本文把变量、参照状态和保持不变的边写入实验合同，使结论可以复现到同一操作。

一阶边归因的主要计算优势是只需一次反向传播即可同时给出多个组件的局部预测。其误差来源包括梯度沿位移方向变化、softmax 饱和、非线性门切换和路径间抵消[32-33]。因此第 7 章既报告绝对误差与相对误差，也报告头间排序相关；前两者评价数值近似，后者评价资源筛选场景中的顺序信息。

2.5 方法定位

表 2-1 方法对象与评价方式比较

方法	主要对象	需要外部参照状态	分解内部路径	完整性或闭合对象	评价有限内部替换
输入乘梯度	当前点输入坐标	否	否	一般不满足函数值完整性	非固有目标
Integrated Gradients	输入路径归因	是	否	路径归因完整性	通常评价输入扰动
Conductance	隐藏单元路径归因	是	隐藏单元，不是图边切面	对其路径对象完整	可评价神经元消融
FullGrad	输入项与偏置项	否	分层偏置项	全梯度表示完整性	通常评价输入扰动
注意力展开	跨层注意力流	否	注意力矩阵	无类别分数闭合	通常评价输入标记扰动
GlobEnc / ALTI	编码器标记贡献	否	标记或组件传播	依各自分解定义	通常评价输入标记
DecompX	预测的标记表示分量	否	编码器组件	指定标记分解	评价标记删除
AttnLRP	输入与隐层相关性	否	注意力与跳跃连接	相关性守恒	评价输入扰动
LibraGrad	ViT 输入归因	否	修改的反向路径	以 FullGrad 完整性为目标	评价输入扰动
激活替换	内部变量的有限效应	是	选定节点或边	非加和完整性目标	直接评价
边归因近似	计算边有限效应的一阶估计	是	是	非加和完整性目标	与真实替换比较
本文 NNS – ViT	ViT 目标和真实边的局部输入图	图本身否；替换评价是	指定查询/键/值、头和残差切面	合法切面的局部微分闭合	规定替换任务

2.6 文献评述与研究空间

已有研究已经覆盖输入梯度、路径归因、Transformer 标记分解和内部替换。尚待系统连接的是：在不改变实际局部雅可比矩阵的情况下，把 ViT 异构目标统一映射回输入坐标；按真实边构造可核验的局部微分切面；再将正确性、层深描述和有限替换效用分开评价。本文围绕这一连接开展研

究。

表 2-1 还揭示本文与最接近方法的三点差别。与输入乘梯度相比，本文增加的是内部目标注册和结构切面，而不是改变终点公式；与 Transformer 标记分解相比，本文研究实际局部雅可比在输入像素坐标中的路径分项；与激活替换相比，本文先建立不依赖外部参照状态的局部结构图，再用参照状态明确的替换任务评价其边界。这三点共同构成后续章节的比较框架。

2.7 本章小结

本章从研究对象、参照状态、内部路径和效用评价四个维度梳理了相关方法。NNS – ViT 在已有基础归因之上，为指定 ViT 计算图提供统一目标注册、真实边分解和分层证据。

第 3 章 NNS 的数学基础与边界

3.1 本章问题

本章回答 RQ1：逐层传播的 NNS 学习图像在一般计算图上对应什么数学对象；它在何种条件下等于输入乘梯度；坐标原点、非齐次项和不可微点如何限制解释。

3.2 方法：计算图上的学习图像

设网络为有向无环计算图 $G=(V,E)$，输入为列向量 $x\in\mathbb R^d$，目标为标量 $s(x)$。对中间变量 $u(x)\in\mathbb R^m$，定义学习图像矩阵 $\mathcal L(u;x)\in\mathbb R^{m\times d}$。输入初始化与多输入算子传播为

式（3-1）

$$\mathcal L(x;x)=\operatorname{diag}(x),\qquad \mathcal L(v;x)=\sum_{a=1}^{r}J_{f,u_a}(x)\mathcal L(u_a;x),\quad v=f(u_1,\ldots,u_r).$$

式（3-1）在实际前向状态计算每个局部雅可比矩阵。线性层、卷积层和当前 ReLU 门使用通常导数；最大池化使用当前前向获胜位置；ReLU 零点和最大值并列使用框架固定的导数选择。

命题 3-1（标量目标等价性）。 若所有局部雅可比矩阵在同一当前前向状态求值，传播中不加入归一化、截断或相关性重分配，则

式（3-2）

$$\mathcal L(u;x)=J_{u,x}(x)\operatorname{diag}(x),\qquad E_s(x)=\mathcal L(s;x)^\top=\operatorname{diag}(x)\nabla_xs(x).$$

证明。 输入处 $J_{x,x}=I$，式（3-2）对输入成立。按拓扑顺序假设所有前驱均满足该式，把它们代入式（3-1），由多输入链式法则得到 $J_{v,x}\operatorname{diag}(x)$。归纳到标量目标并转置，即得 $E_s(x)=x\odot\nabla_xs(x)$。

该量刻画输入坐标缩放方向的一阶响应。令第 i 个坐标发生 $x_i\mapsto(1+\epsilon)x_i$，则

式（3-3）

$$s(x+\varepsilon x_i e_i)-s(x)=\varepsilon E_{s,i}(x)+o(\varepsilon).$$

一般网络满足

式（3-4）

$$\sum_{i=1}^{d}E_{s,i}(x)=x^\top\nabla_xs(x)\neq s(x).$$

只有一阶齐次函数在可微点可由 Euler 定理得到等号。带偏置、类别标记、位置编码、层归一化、softmax 和 GELU 的 ViT 通常不满足该条件。

若原始像素 r 经 $x=(r-\mu)/\sigma$ 标准化，则

式（3-5）

$$x_i\frac{\partial s}{\partial x_i}=(r_i-\mu_i)\frac{\partial s}{\partial r_i}.$$

因此局部输入图不需要另选干预参照状态，却依赖模型输入坐标的原点。

3.3 验证方法

公式验证覆盖全连接网络、卷积网络、带最大池化卷积网络、残差多层感知机和残差卷积网络。每类网络使用 100 个输入、两种数值精度，共 5 000 次逐层传播与自动微分输入乘梯度比较。另以 11 类算子的 88 个方向检查局部导数，以有限差分和解析雅可比—向量积核验方向响应。

验证采用三种互补机制。公式回归比较两条独立计算路径：一条显式传播学习图像，另一条直接由自动微分得到输入梯度后与输入相乘。算子方向检查把复杂网络拆为线性层、卷积、池化、归一化和非线性等局部对象，验证每个局部雅可比的方向响应。有限差分则不复用解析反向公式，通过目标值在小扰动下的变化检验一阶预测。

浮点精度会同时影响目标差分和相对误差分母。当目标对给定方向的响应很小时，单精度差分可能由舍入误差主导。本文预先保留单精度超差记录，并在相同输入、坐标和方向上用双精度复核，而不是删除困难样本或放宽容差。这一程序把数值条件问题与公式身份问题分开。

3.4 结果

表 3-1 NNS 公式回归的最大相对二范数误差

兼容网络	双精度	单精度	比较次数
全连接网络	4.371×10^{-16}	1.964×10^{-7}	1 000
卷积网络	4.289×10^{-16}	2.189×10^{-7}	1 000
卷积网络加最大池化	4.769×10^{-16}	2.427×10^{-7}	1 000
残差多层感知机	2.686×10^{-16}	2.155×10^{-7}	1 000
残差卷积网络	2.923×10^{-16}	1.692×10^{-7}	1 000

五类网络的双精度最大误差不超过 4.769×10^{-16}，单精度最大误差不超过 2.427×10^{-7}。88 项算子方向检查全部通过。ViT 图册的 57 600 项单精度有限差分中有 36 项超过预设容差；相同坐标的 36 项双精度复核全部通过，原失败记录保留。结果验证了式（3-2）对应本文实现，但该数值结果不构成对不可获得的原作者软件实现的复现。

3.5 讨论

命题 3-1 把 NNS 标量终点确定为已有的输入乘梯度，并说明学习图像可以通过统一自动微分实现。式（3-4）与式（3-5）给出两个必要边界：局部输入图通常不重构函数值，并且会随输入坐标原点改变。后续章节的贡献建立在这一局部量之上，集中于 ViT 内部目标和结构路径。

对向量内部目标，学习图像矩阵的每一行对应一个标量坐标。通道能量等聚合目标先把向量映射为标量，再使用同一传播规则；这避免把具有不同下游余切的坐标直接相加。对多输入算子，式（3-1）显式求和各输入边的雅可比项，因此共享张量的多次使用必须按计算边区分。第 4 章的合法切面正是这一多输入链式法则在 ViT 上的结构化应用。

局部图的符号也需要与显示分开。正值表示沿当前坐标缩放方向增加目标的一阶项，负值表示降低目标的一阶项；绝对质量用于研究空间范围，会丢弃方向但保留幅度。蓝底正部视图只显示前一种形态。本文在所有统计中保留带符号原始数组，并在需要空间分布时明确转换为绝对质量。

3.6 本章小结

本章通过命题、证明和 5 000 次数值回归回答了 RQ1。在精确当前点局部导数条件下，标量 NNS 学习图像等于输入乘梯度；其解释对象是坐标相关的局部一阶响应，函数值完整性需要另行定义。

第 4 章 ViT 结构路径分解方法

4.1 本章问题

本章回答 RQ2：如何将 ViT 异构目标映射到输入空间，如何按真实计算边分解注意力与残差，以及何种条件保证分项闭合。最后通过重参数化反例界定分解的非唯一性。

4.2 方法：内部标量目标注册

ViT 的图像块投影把局部像素映射为标记向量，学习图像仍保留原像素坐标。本文注册四类目标：单个标记—通道标量、跨空间标记的通道聚合、结构边目标及类别输出。对通道 c 的图像块标记激活 $h_{t,c}$，定义能量聚合目标

式（4-1）

$$s_{\mathrm{eng}}=\frac12\sum_{t=1}^{196}h_{t,c}^{2},\qquad E_{\mathrm{eng}}=\sum_{t=1}^{196}h_{t,c}E_{h_{t,c}}.$$

式（4-1）对应激活加权的通道聚合，其统计对象是多个空间标记形成的聚合标量。其他目标包括图像块标记求和、注意力头内部坐标、最终类别标记通道、真实类别逻辑值和冻结原输入最高预测类别逻辑值。跨模型同编号通道分别分析。

目标注册需要同时保存目标语义、张量位置、聚合规则和下游标量。标记—通道目标保留位置与通道编号；通道聚合目标记录参与的 196 个图像块标记；注意力头目标记录编码块、头和输出投影前边；类别目标记录类别索引及其冻结方式。注册表使同一执行器可以处理不同形状对象，也避免图示中选择的通道被误当作总体抽样通道。

目标类型决定可回答的问题。单个标记—通道适合研究局部性与输入距离，能量聚合适合连接前向通道响应和输入依赖，真实类别逻辑值适合比较结构路径，而原输入最高预测类别用于目标敏感性控制。各类目标共享输入坐标，却不在数值上直接混合。

4.3 方法：注意力路径

对单个注意力头，令

式（4-2）

$$Q=XW_Q+b_Q,\quad K=XW_K+b_K,\quad V=XW_V+b_V,\quad A=\mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_h}}\right),\quad O_h=AV.$$

其局部微分为

式（4-3）

$$\mathrm dO_h=(\mathrm dA)V+A\,\mathrm dV,\quad \mathrm dA=J_{\mathrm{softmax}}\mathrm dS,\quad \mathrm dS=\frac{\mathrm dQK^\top+Q\mathrm dK^\top}{\sqrt{d_h}}.$$

式（4-3）的前两项分别定义查询诱导路径和键诱导路径，两者合为路由路径；$A\mathrm dV$ 定义值诱导的取值路径：

式（4-4）

$$E^{\mathrm{attn}}=E^{Q}+E^{K}+E^{V}=E^{\mathrm{route}}+E^{\mathrm{value}}.$$

注意力头边位于拼接和输出投影之前。每个头的下游余切包含输出投影及目标之后的全部导数，所以

式（4-5）

$$E^{\mathrm{MHA}} = \sum_{h=1}^{H} E_h.$$

式（4-4）和式（4-5）描述同一局部微分的路径分组。查询、键和值共享上游输入，分项允许在输入空间重叠；路径范数比例用于比较局部尺度。

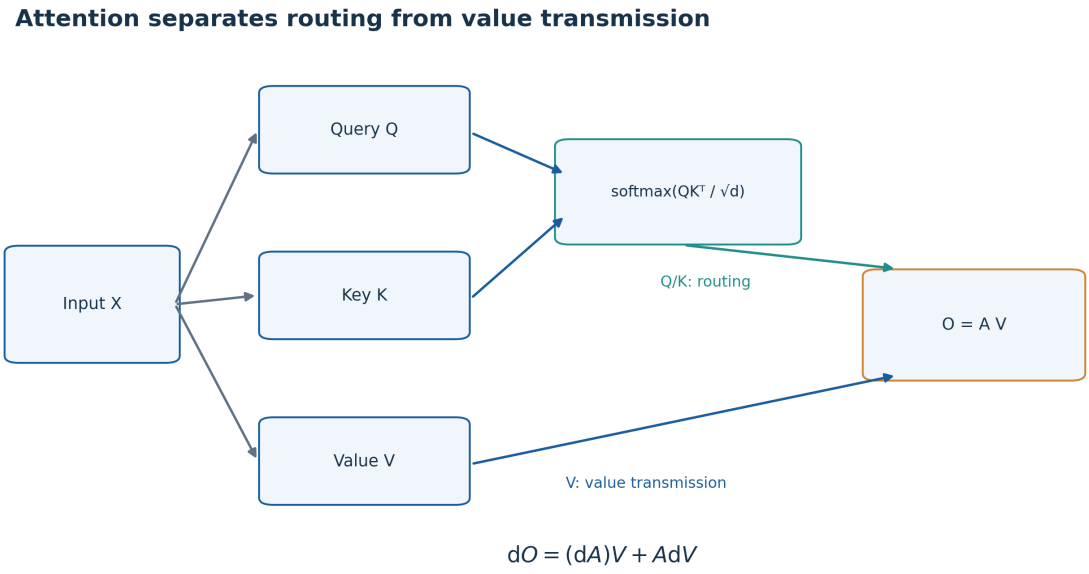


图 4-1 注意力微分路径。 查询和键改变注意力权重，值在当前权重下传递内容；三项在指定切面上重构完整注意力微分。

4.4 方法：残差路径与合法计算切面

对残差计算 $y=u+f(u)$ 和下游标量 F，令 $g_y=\nabla_yF$。恒等路径与分支路径定义为

式（4-6）

$$E^{\mathrm{id}} = \mathrm{diag}(x) J_{u,x}^{\top} g_y, \qquad E^{\mathrm{branch}} = \mathrm{diag}(x) J_{u,x}^{\top} J_{f,u}^{\top} g_y.$$

恒等项必须使用残差输出处的 g_y。若直接把已含分支效应的 ∇_uF 作为恒等项，再加分支项，就会重复计算。

对目标 F 的切面边集合 $C=\{z_k\}$，定义第 k 条边在输入坐标 i 上的路径项

式（4-7）

$$E^{C}_{k,i} = x_i \left\langle g_{z_k}, \frac{\partial z_k}{\partial x_i} \right\rangle.$$

命题 4-1（合法计算切面闭合）。 若从输入到目标的每条相关微分路径恰好穿过切面一次，各项使用同一前向状态，余切位于相应真实使用边，且无旁路遗漏和路径重复，则式（4-7）的分项满足

式（4-8）

$$\sum_{k\,:\,z_k \in C} E^{C}_{k,i} = x_i \frac{\partial F}{\partial x_i}.$$

证明。 将链式法则展开为所有输入到目标路径的雅可比乘积。合法切面把这些路径不重不漏地分组；每组可分解为到达 z_k 的上游雅可比与该边的下游余切。对全部组求和并乘 x_i，得到式（4-8）。只切分支会遗漏恒等旁路；完整输入梯度与分支项相加则会重复分支。

合法切面的构造可写成四步。第一，确定唯一标量目标及当前前向状态。第二，从目标逆向枚举希望解释的真实使用边，并检查是否存在绕过这些边的路径。第三，为每条边保存其上游输入雅可比作用和边上的下游余切。第四，将分项相加与完整局部输入图逐元素比较，同时构造至少一个遗漏旁路和一个重复路径负控制。正向闭合与负控制必须同时成立，才能排除“所有分项都接近零”造成的伪通过。

多头注意力尤其需要按使用边而非张量存储位置切分。拼接后的输出张量已经混合头维度，输出投影又把头坐标旋转到模型维度。本文在投影前截取每个头的实际使用边，并让下游余切穿过同一个输出投影；这样式（4-5）的头和与原前向计算保持一致。残差切面同理必须同时包含恒等输入边和分支输出边。

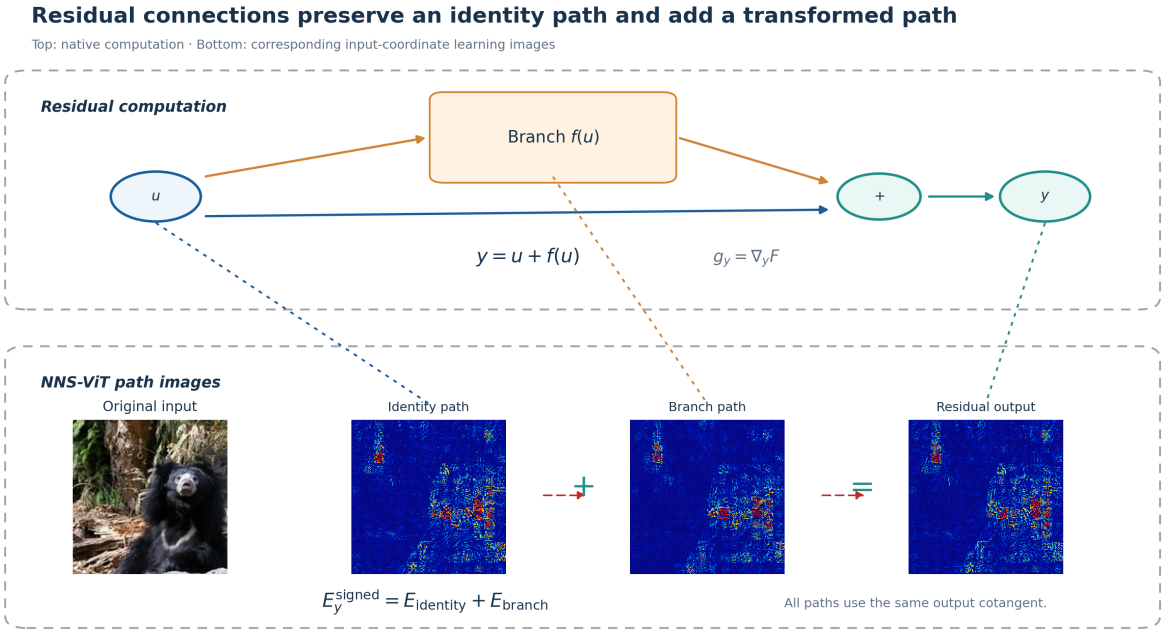


图 4-2 残差路径。 恒等边与分支边使用同一输出余切；带符号路径图相加恢复残差输出的局部输入图。

4.5 方法：图依赖与非唯一性

考虑 $x=(x_1,x_2)^\top$、隐藏变量 $h=x$ 和输出 $s=(1,1)h=x_1+x_2$。按隐藏坐标切分得到

式（4-9）

$$E_1 = (x_1, 0)^\top, \qquad E_2 = (0, x_2)^\top.$$

令

式（4-10）

$$R=\begin{bmatrix}1&1\\0&1\end{bmatrix},\qquad h'=Rh,\qquad w'=R^{-\top}(1,1)^\top=(1,0)^\top.$$

由式（4-10），同一函数可写为 $s=w'^\top h'$，新隐藏坐标下的分项为

式（4-11）

$$E'_1=(x_1,x_2)^\top,\qquad E'_2=(0,0)^\top.$$

式（4-9）和式（4-11）的总和相同，但分项不同。因此路径图相对于指定计算图、切面和参数化定义。闭合说明给定记账没有遗漏或重复；分项唯一性需要额外的不变性条件。

该反例不是实现缺陷，而是内部贡献分解的一般识别问题。若研究问题关心端到端函数不变量，应使用总输入梯度、函数值或经证明不变的对象；若研究问题关心具体实现中信息经由哪些边传播，则图相对分解是合适对象，但必须报告实现和切面。本文选择后一问题，并把模型权重、软件路径与目标注册冻结为可复现条件。

切面粒度还会改变解释分辨率。把整个注意力子层作为一项只能比较子层与恒等路径；按头切分可比较头；在头内按查询、键和值切分可比较路由和内容传递。更细切面增加诊断能力，也增加项间抵消和多重比较负担。本文只在能够由真实边和同一余切定义、且有直接闭合验证的三个粒度上报告结果。

4.6 方法：空间与尺度指标

对像素 p 的三通道局部图，定义绝对质量和图像块质量分布

式（4-12）

$$M(p)=\sum_{c\in\{R,G,B\}}|E_{p,c}|,\qquad m_j=\sum_{p\in P_j}M(p),\qquad q_j=\frac{m_j}{\sum_k m_k}.$$

总质量为零时，q_j 记为缺失值。归一化空间熵、目标图像块邻域局部性和归一化距离分别衡量分布范围、近邻集中和到目标位置的距离。查询/键/值总体分析另使用两次从 q 独立抽样所得位置距离的期望，从而不需要人为选定目标图像块。带符号图的抵消率定义为

式（4-13）

$$C_{\mathrm{map}}=1-\frac{|\sum_i E_i|}{\sum_i |E_i|},\qquad C_{\mathrm{path}}=1-\frac{\|E^{(1)}+E^{(2)}\|_1}{\|E^{(1)}\|_1+\|E^{(2)}\|_1}.$$

路由相对尺度为

式（4-14）

$$S_{\mathrm{route}}=\frac{\|E^{\mathrm{route}}\|_1}{\|E^{\mathrm{route}}\|_1+\|E^{\mathrm{value}}\|_1},$$

残差恒等相对尺度同理。式（4-13）用于报告正负项与路径间抵消。仅保留 $A\mathrm dV$ 的值路径近似误差为

式（4-15）

$$\varepsilon_V=\frac{\|E^{\mathrm{attn}}-E^{V}\|_2}{\|E^{\mathrm{attn}}\|_2}.$$

4.7 结构闭合结果

两模型共完成 76 800 项查询/键/值、路由/取值、多头及残差正向闭合，全部通过；28 800 项故意遗漏或重复路径的负控制全部被拒绝；6 144 项解析雅可比—向量积检查全部通过。独立复算的最大查询/键/值闭合绝对误差为 1.574×10^{-5}，最大残差闭合绝对误差为 2.480×10^{-5}。结果支持指定冻结图上的结构记账正确性。

闭合验证覆盖两种模型的全部 400 张评价图和 12 个编码块，因此既检查不同输入，也检查浅层到深层的数值条件变化。负控制分别省略恒等旁路、重复分支或破坏完整切面；它们在同一容差下被拒绝，说明正向通过来自正确路径集合，而不是宽松容差。解析雅可比—向量积检查则直接比较局部方向响应，补充了输入空间分项加和。

计算成本主要由目标反向传播和需要保存的中间边决定。一个标量目标的完整局部图只需一次反向传播；路径分项可以在同一前向状态上复用上游状态与下游余切，但大量标记—通道目标仍需分块执行。本文通过冻结目标注册、按图像任务化和流式汇总控制存储，同时保留少量完整原始图用于独立复算和可视化。

4.8 本章小结

本章以目标注册、真实边和合法切面回答了 RQ2。查询、键、值、注意力头及残差分项能够在指定图上闭合；反例同时表明分项随内部坐标和切面改变。后续经验结论均指向本文冻结实现中的这些明确定义对象。

第 5 章 研究设计与统计分析

5.1 模型、数据与样本形成

实验使用 ViT-B/16 和 DeiT-S/16 两个 ImageNet-1K 预训练分类模型[1-2]。两模型均含 12 个编码块；前者有 12 个注意力头、隐藏维 768，后者有 6 个注意力头、隐藏维 384。输入短边缩放至 248 像素后中心裁剪为 224×224，采用各模型规定的标准化参数；推理关闭随机失活和随机深度。

样本形成采用确定性哈希规则。先保留至少含一张非排除图像的类别，用“ 命名空间—类别—WordNet 标识符 ”的 SHA-256 排序选择前 528 类；每类内部再用“ 命名空间—图像—文件名 ”的 SHA-256 排序选择一张图像。排序后的前 64 张为发现集，后 64 张为校准集，其余 400 张为评价集。三组互不重叠，每类至多贡献一张图像。主要总体实验在两个模型间共享同一 400 张评价图。

这一规则优先获得类别覆盖，并使分组完全由结果无关的元数据决定。发现集用于实现调试和图形方案，校准集用于固定数值容差与显示规则，评价集用于主要统计；评价图像在协议冻结前不会因模型输出或学习图像外观被选择。每类一图减少类别频数不平衡对图像级汇总的影响，但相应总体更接近“ 被选类别的一图分布 ”，而不是 ImageNet 同类图像的自然频率分布。

分层单元研究使用冻结的 100 图子集，每层抽取类别标记、15 个空间分层图像块标记和 32 个通道。每个模型—图像包含 6 144 个块后标量，共 1 228 800 个记录。五组独立复现保持这 100 张图不变，分别用互不相同、在结果读取前冻结的命名空间重新抽取 16 个标记和每层 32 个通道。参数状态对照使用每模型 32 张共享图像、三个独立随机初始化状态和同架构预训练状态。

标记抽样覆盖类别标记和空间分层图像块，通道抽样在每层独立生成。五组复现改变标记与通道目标，而不改变图像，因此检验层深方向是否依赖某一组内部目标；图像级自助法则在每组内部量化图像总体的不确定性。两者对应不同随机性来源，不能互相替代。

表 5-1 模型与主要样本

项目	ViT-B/16	DeiT-S/16
编码块数	12	12
注意力头数	12	6
隐藏维度	768	384
每图注册标量目标数	457	385
主要评价图像数	400	400
分层单元图像数	100	100
参数状态对照图像数	32	32
随机初始化状态数	3	3

5.2 有限替换设计

多幅度实验把注意力头输出 z 从原输入状态插值到参照状态：

式（5-1）

$$z_\alpha = (1-\alpha)z_{\mathrm{clean}} + \alpha z_{\mathrm{ref}}, \qquad \alpha \in \{0.05, 0.10, 0.25, 0.50, 1.00\}.$$

真实有限效应和一阶预测定义为

式（5-2）

$$e_\alpha = F(z_{\mathrm{clean}}) - F(z_\alpha), \qquad p_\alpha = \alpha \langle \nabla_z F, z_{\mathrm{clean}} - z_{\mathrm{ref}} \rangle.$$

参照状态分别由归一化零输入和模糊输入产生。实验固定同一 400 图、真实类别逻辑值、12 层全部注意力头和两种参照状态。报告真实效应绝对值、预测绝对值、绝对误差、相对误差及图内头间斯皮尔曼秩相关（Spearman correlation）。

归一化零输入把模型坐标原点映射为参照状态，模糊输入保留低频颜色和轮廓但削弱细节。两种参照产生不同内部位移，能够检验局部排序是否依赖参照选择。多幅度实验沿每个具体原状态—参照状态方向取五个位置；它不是随机噪声强度扫描，而是对同一替换任务的距离连续化。

完整成分替换使用

式（5-3）

$$e_k = F(x) - F(x; z_k \leftarrow z_k^{\mathrm{ref}}), \qquad p_k = \left\langle \nabla_{z_k} F, z_k(x) - z_k^{\mathrm{ref}} \right\rangle.$$

区域任务固定第 5 个编码块的三个注意力头，把输入划分为 4×4 候选区域，依次替换 1、2、4 个区域，即最高 25% 面积。每条曲线先取隔离效应绝对值，在面积 0 – 25% 上积分并除以 0.25，再在图内平均三个头。候选上界只在实际评价区域集合中取最优，不表示所有可能区域的全局最优。

成分排序与区域选择使用不同候选集合。成分任务在同一结构族内比较头或残差边，区域任务则在固定头内比较空间子集。前者用 Spearman、前若干项捕获率和遗憾值评价组件筛选；后者用绝对效应曲线下面积评价有限预算内逐步加入区域的收益。二者共同研究排序，但不能把一个任务的阈值直接移到另一个任务。

5.3 统计原则

所有总体推断先对同一图像内的标记、通道、头或层聚合，再把图像作为唯一统计单位。区间采用图像级自助法[36]；原确认性检验的 28 项族使用霍尔姆（Holm）校正[37]。0.10 的成分相关门槛和 0.05 的区域增益门槛在结果读取前冻结，用于判定复合规则。除非另行说明，区间为 95% 区间。

图内聚合避免把共享同一输入和网络状态的大量单元误当作独立样本。中位数用于降低极端梯度范数对总体位置的影响；区间通过重采样完整图像保留图内依赖。独立通道/标记抽样的组间标准差另行报告，因为对同一组数据做更多自助重采样只能估计图像不确定性，不能模拟重新选择内部目标。

多重比较族按研究问题和分析阶段冻结。原确认性族保留原阈值与 Holm 决策；新增 Q/K/V 总体统计和多幅度实验使用其各自冻结的后继合同；事后空间总变差和饱和度分析单独解释，不进入原复合结论。这一分层防止补充发现改变既有失败或成功标签。

确认性分析指在结果读取前冻结样本、目标、估计量、阈值和多重比较族的分析。补充分析在不改变原决策的条件下检验参数状态、目标和方法关系。事后分析用于解释已观察模式，单独成族且不提升原确认性结论。

5.4 研究问题与估计量总表

表 5-2 研究问题—估计量—统计单位—样本数—分析性质—结论

研究问题	主要估计量	统计单位	样本数	分析性质	可得结论
RQ1 数学身份	相对二范数误差、方向误差	网络—输入比较	5 类网络，各 1 000 次	方法验证	当前实现与式（3-2）一致
RQ2 结构闭合	最大绝对误差、相对误差、负控制拒绝	图像—块—路径	400 图/模型；76 800 正向项	确认性正确性验证	指定图与合法切面上的记账闭合
RQ3 单元空间范围	熵、局部性、归一化距离的后期减前期差	图像	100 图/模型；5 个独立抽样组	确认性后继复现	两个固定参数状态的抽样目标稳定扩展
RQ3 查询/键/值	绝对质量、熵、成对距离、抵消率、相对尺度的第 11 块减第 0 块差	图像	400 图/模型	确认性补强	三条路径的总体层深轨迹不同
RQ3 路由/取值与残差	相对尺度、近似误差、绝对质量	图像	400 图/模型	确认性描述	深层路由占比和仅值路径误差提高；残差子层不同

研究问题	主要估计量	统计单位	样本数	分析性质	可得结论
RQ3 参数状态	预训练状态减随机状态的层深差	图像与随机种子	32 图/模型，3 个随机状态	补充分析	参数状态存在差异，不识别训练因果效应
RQ4 多幅度	绝对/相对误差、头间斯皮尔曼秩相关	图像	400 图/模型，2 种参照状态	确认性后继实验	规定插值任务的一阶误差随幅度扩大
RQ4 成分排序	斯皮尔曼秩相关、前 k 项捕获率、遗憾值	图像	400 图/模型	原确认性与冻结补充	局部图关联广泛但并非普遍；泰勒排序通常更强
RQ4 区域选择	绝对效应曲线下面积、配对差、归一化遗憾值	图像	400 图/模型	原确认性；跨层为补充	原局部图复合主张未获支持，区域泰勒更适配
饱和度与空间敏感性	偏秩相关、空间总变差	图像	400 图/模型	事后分析	仅用于解释注意力与残差模式

5.5 可视化与证据管理

主图中的蓝底视图显示带符号三通道和的正部，并使用固定分位数和平方根显示变换增强弱结构。该变换不参与任何统计。原始带符号图、绝对值图和显示参数保留在证据包中。示例图按可读性选择；总体结论全部来自表 5-2 所列完整样本。数值文件、图源和校验收据通过 SHA-256 绑定。

证据管理遵循“原始量—图像级汇总—正文数值”三层映射。原始量保存路径分项和真实替换结果，分析文件从原始量重新计算图像级统计，正文表格只取已封存字段。独立校验器复算选定原始量、检查样本数和公式，并比较双语表格数字。显示图的像素哈希只用于确认排版资产，科学结论仍绑定原始数值文件。

5.6 本章小结

本章明确了确定性样本形成、模型设置、有限替换算子和图像级推断原则。表 5-2 将每个研究问题与估计量、统计单位、样本数和分析性质绑定，使理论恒等式、数值正确性、描述性规律和干预效用保持分离。

第 6 章 结构路径的层深规律

6.1 本章问题

本章回答 RQ3：内部目标的局部输入依赖是否随深度扩大；查询、键和值路径是否具有相同轨迹；路由/取值路径与残差恒等/分支路径怎样变化；这些结果对独立目标抽样和参数状态是否稳定。

6.2 方法

单元分析把编码块 0 – 3、4 – 7、8 – 11 分别定义为前期、中期和后期，对每图先聚合抽样标记与通道，再计算后期减前期差。五组独立抽样使用相同 100 图，但重新抽取标记和通道；方向一致率按模型—组—指标统计。

查询/键/值总体分析使用每模型 400 图、12 层和冻结真实类别逻辑值。对三条路径分别计算式（4-12）至式（4-14）所定义的绝对质量、熵、归一化成对距离、抵消率和相对尺度，并报告第 11 块减第 0 块的图像级中位差与区间。注意力路由/取值与残差分析使用同一 400 图和全部注意力头，并用式（4-15）量化仅值路径近似误差。

6.3 结果：单元学习图像与独立抽样

原冻结抽样中，ViT-B/16 的熵后期减前期为 0.2201，局部性为 −0.3558，归一化距离为 0.1312；DeiT-S/16 分别为 0.2250、−0.3424 和 0.1219。每项对比的全部 100 张图均呈同一方向。

五组独立抽样的 30 个模型—抽样组—指标组合全部复现熵增加、局部性下降和距离增加。表 6-1 给出每组的图像级中位差。

表 6-1 五组独立标记—通道抽样的后期减前期差

模型	指标	第 1 组	第 2 组	第 3 组	第 4 组	第 5 组
ViT-B/16	熵	0.2351	0.2273	0.2179	0.2313	0.2247
ViT-B/16	局部性	−0.3685	−0.3646	−0.3537	−0.3634	−0.3618
ViT-B/16	距离	0.1500	0.1473	0.1432	0.1445	0.1450
DeiT-S/16	熵	0.2246	0.2301	0.2244	0.2271	0.2189
DeiT-S/16	局部性	−0.3408	−0.3453	−0.3357	−0.3413	−0.3401
DeiT-S/16	距离	0.1311	0.1344	0.1294	0.1347	0.1320

组间标准差在 ViT-B/16 的熵、局部性和距离上分别为 0.00653、0.00546 和 0.00270；DeiT-S/16 分别为 0.00409、0.00342 和 0.00225。结果把结论从单一目标抽样推进到两个固定参数状态中的五组独立目标抽样复现。

表 6-1 的组间变异远小于各指标的中位层深差。例如 ViT-B/16 的五组熵差范围为 0.2179 – 0.2351，而组间标准差为 0.00653；DeiT-S/16 的局部性差范围为 −0.3453 至 −0.3357，组间标准差为 0.00342。稳定性体现在方向和量级两个方面，而不是仅由区间是否跨零判定。

熵、局部性和距离从不同角度描述同一空间变化。熵增加表示绝对质量分布更均匀地覆盖图像块；局部性下降表示目标图像块邻域占比降低；距离增加表示质量重心相对目标位置向远处移动。三项同时出现，排除了“只在原邻域内变均匀”或“少数远端热点增加但总体仍高度局部”这两种单指标解释。

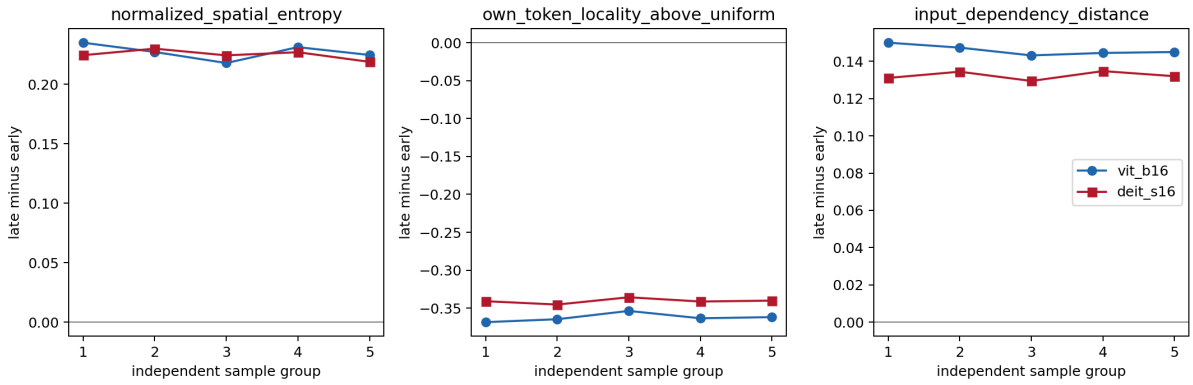


图 6-1 五组独立抽样。 每点为图像级聚合后的层深差；各组使用独立冻结的标记—通道抽样。

6.4 结果：查询、键和值路径

表 6-2 查询、键和值路径第 11 块减第 0 块的图像级中位差及 95% 区间

模型	路径	绝对质量	熵	成对距离	抵消率	相对尺度
ViT-B/16	查询	208.8022 [193.7022, 229.1715]	0.0268 [0.0217, 0.0314]	0.0108 [0.0071, 0.0143]	0.0099 [0.0083, 0.0122]	0.0427 [0.0220, 0.0549]
ViT-B/16	键	308.5203 [285.6579, 347.7998]	−0.0586 [−0.0636, −0.0528]	−0.0109 [−0.0150, −0.0073]	0.0104 [0.0093, 0.0123]	0.2553 [0.2449, 0.2675]
ViT-B/16	值	255.5471 [235.9237, 295.1770]	−0.0530 [−0.0591, −0.0471]	−0.0082 [−0.0106, −0.0052]	0.0018 [0.0015, 0.0023]	−0.3088 [−0.3249, −0.2882]
DeiT-S/16	查询	91.9272 [86.3993, 98.2857]	−0.0038 [−0.0080, 0.0005]	−0.0021 [−0.0046, 0.0022]	0.0192 [0.0177, 0.0223]	0.1292 [0.1169, 0.1376]
DeiT-S/16	键	140.0030 [128.9647, 148.3989]	−0.0669 [−0.0736, −0.0590]	−0.0100 [−0.0140, −0.0059]	0.0119 [0.0106, 0.0144]	0.2581 [0.2507, 0.2649]
DeiT-S/16	值	73.3232 [63.7414, 84.2214]	−0.0669 [−0.0748, −0.0609]	−0.0054 [−0.0094, −0.0021]	0.0027 [0.0021, 0.0032]	−0.3915 [−0.4044, −0.3840]

键和值路径在两个模型中均随深度增加绝对质量和抵消率，同时降低熵与成对距离；键路径相对尺度增加，值路径相对尺度降低。查询路径的绝对质量、抵消率和相对尺度也在两个模型中增加，但空间方向不一致：ViT-B/16 的熵与距离增加，DeiT-S/16 的估计略降且区间跨零。因此三条路径需要分别报告其扩展或收缩方向。

绝对质量与相对尺度的联合报告防止比例误读。值路径的绝对质量在两个模型中都增加，但其相对尺度下降，原因是查询和键形成的路由项增长更快。键路径的绝对质量和相对尺度同时增加，说明它在完整注意力局部微分中的相对权重也上升。查询路径的空间指标跨模型不同，则提示模型架构、参数状态或归一化可能改变其空间组织。

抵消率随深度增加意味着带符号项在相加前的总幅度与相加后的净幅度差距扩大。因此图中较亮的绝对质量不能直接解释为同方向的输出支持。本文用绝对质量分析“分布在哪里”，用带符号和及有限替换分析“方向与效应是什么”，两者在结果解释中保持分开。

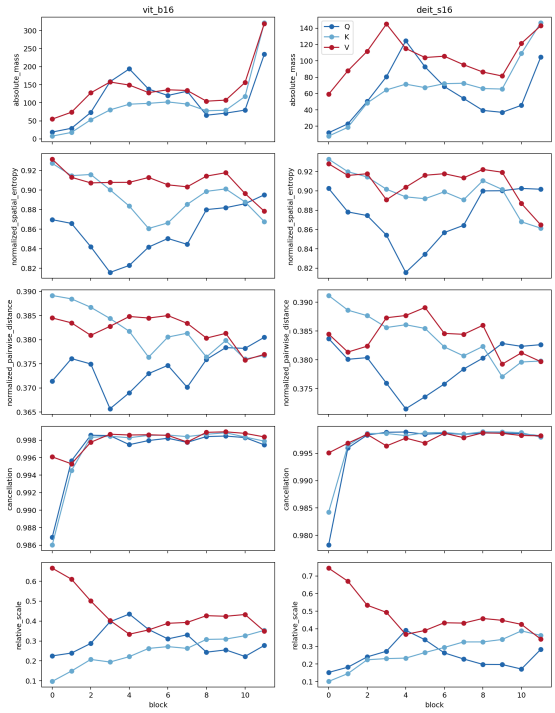


图 6-2 查询、键和值总体轨迹。 每模型 400 图、12 层，阴影为图像级 95% 自助区间。

6.5 结果：路由、取值与残差

ViT-B/16 的路由相对尺度中位数由第 0 块的 0.3092 增至第 11 块的 0.5154；DeiT-S/16 由 0.2041 增至 0.4808。仅值路径误差在 ViT-B/16 中由 0.4407 增至 0.8022，在 DeiT-S/16 中由 0.2774 增至 0.8488。

表 6-3 注意力路径的绝对质量中位数

模型	编码块	路由绝对质量	取值绝对质量	完整注意力绝对质量
ViT-B/16	0	2.6596	7.6041	9.8604
ViT-B/16	11	40.7842	39.0241	54.6768
DeiT-S/16	0	4.5294	18.4261	20.1427
DeiT-S/16	11	35.9257	38.8767	44.5653

解析方向响应的深层差异率为 0.9516 和 0.9636；相应完整响应范数为 14.9711 和 1.5155，绝对差异为 13.8064 和 1.4228。比例和绝对量共同说明，深层中固定注意力权重的 $A\mathrm dV$ 难以近似完整局部响应。

残差路径呈现不同模式。注意力残差恒等相对尺度的后期减前期差在 ViT-B/16 为 −0.1242，在 DeiT-S/16 为 −0.0449；多层感知机残差则分别为 0.1798 和 0.1780。注意力输出相对恒等路径的空间总变差随深度增加 0.0520 和 0.0282，多层感知机对应变化为 −0.0187 和 −0.0462。四项属于单独成族的事后空间分析。

注意力与多层感知机残差的相反方向不能简化为“深层更依赖分支”这一单一叙述。注意力残差中恒等相对尺度下降，与路由项增长一致；多层感知机残差中恒等相对尺度上升，说明其分支和恒等路径的尺度平衡不同。空间总变差提供第二个观察维度：相对尺度改变与空间分布改变可以同向，也可以分离。

仅值路径误差从约 0.28 – 0.44 升至约 0.80 – 0.85，表明深层注意力的权重变化项在目标条件化局部响应中不可忽略。该结论针对微分响应，不否定值向量在前向内容传递中的作用；它说明以冻结注意力权重近似完整输入敏感性时，深层误差更大。

6.6 补充结果：参数状态、目标和前向特征

三个随机初始化状态也出现空间扩展，但幅度不同。ViT-B/16 预训练状态的熵后期减前期为 0.2288，随机状态均值为 0.0940，差值为 0.1348 [0.1232, 0.1466]。DeiT-S/16 对应为 0.2256、0.1718 和 0.0539 [0.0473, 0.0602]。注意力路由及残差的若干方向也随参数状态改变。这一比较的估计对象是参数状态差异。

在每模型 100 张图、第 0、5、11 块上，真实类别、原输入最高预测类别和最高预测间隔目标均保留路由相对尺度与仅值路径误差增加、注意力恒等相对尺度减少和多层感知机恒等相对尺度增加的方向。错误分类子集在 ViT-B/16 为 8 张，在 DeiT-S/16 为 14 张。

前向通道能量与同通道局部输入绝对质量的图像级 Spearman 均值在 ViT-B/16 为 0.2663，在 DeiT-S/16 为 0.2811；两者高于同层错误通道、跨层同通道、空间置换和随机通道控制。该结果说明二者有关联，但仍描述不同对象。

约 0.27 的相关表明前向响应位置只解释局部输入依赖排序的一部分。前向能量受当前激活大小控制，局部输入图还乘入从目标返回的梯度以及图像块投影到像素的雅可比。正确配对优于四种控制，说明通道身份有信息；相关远低于一，说明只查看前向特征图不足以恢复目标条件化输入依赖。

6.7 讨论

五组独立抽样使“空间扩展”不再依赖单一标记—通道抽样；它适用于两个固定模型参数状态和规定目标分布。查询、键和值的总体统计进一步表明，完整注意力的层深变化需要多路径描述。熵、局部性和距离衡量绝对质量在输入网格上的分布；语义能力需要独立任务评价。

综合来看，RQ3 的主要经验发现不是某一张深层热图看起来更完整，而是多个图像级估计量在独立内部目标抽样中给出一致方向。与此同时，查询路径的跨模型例外、参数状态差异和较弱的特征—局部图相关共同限制了外推范围。这种“稳定主趋势 + 明确例外”的结构比单一案例更适合支持模型内部规律。

6.8 本章小结

RQ3 得到三层证据。抽样内部目标在五组独立抽样中稳定地由局部走向更广、更远；查询、键和值具有不同总体轨迹；深层注意力中的路由相对尺度和仅值路径误差提高，注意力与多层感知机残差方向不同。参数状态对照的结论限定为状态差异。

第 7 章 有限干预中的局部近似与排序

7.1 本章问题

本章回答 RQ4：一阶局部量对注意力头输出插值的误差怎样随干预幅度变化；在完整成分替换和固定面积区域替换中，原输入局部图与参照状态感知的泰勒估计分别具有怎样的排序能力。

7.2 方法

多幅度实验按式（5-1）和式（5-2）执行。每个模型使用同一 400 图、12 层全部注意力头、真实类别逻辑值及两种参照状态。Spearman 相关先在每图每层跨头计算，再平均 12 层。绝对误差为 $|e_\alpha-p_\alpha|$；相对误差使用冻结分母规则，零分母传播为缺失值。

完整成分替换按式（5-3）测量。局部图排序只使用原输入状态；泰勒排序显式使用实际参照位移。区域任务比较局部图、总输入乘梯度、原始梯度、区域泰勒和 20 次随机排序。两类方法的信息预算不同，结果解释为规定任务中的适配性。

7.3 结果：多幅度一阶边界

表 7-1 ViT-B/16 多幅度注意力头输出插值

参照状态	幅度	真实效应绝对值	预测绝对值	绝对误差	相对误差	Spearman
归一化零输入	0.05	0.002922	0.002903	0.000069	0.0272	0.9564
归一化零输入	0.10	0.005795	0.005807	0.000266	0.0524	0.9205
归一化零输入	0.25	0.014466	0.014517	0.001638	0.1216	0.8531
归一化零输入	0.50	0.028453	0.029035	0.006064	0.2231	0.7794
归一化零输入	1.00	0.056748	0.058069	0.021058	0.3913	0.6742
模糊输入	0.05	0.002471	0.002479	0.000057	0.0262	0.9639
模糊输入	0.10	0.004912	0.004957	0.000224	0.0514	0.9289
模糊输入	0.25	0.012021	0.012393	0.001341	0.1212	0.8633
模糊输入	0.50	0.023885	0.024786	0.005077	0.2219	0.7922
模糊输入	1.00	0.046413	0.049572	0.017925	0.3883	0.6856

表 7-2 DeiT-S/16 多幅度注意力头输出插值

参照状态	幅度	真实效应绝对值	预测绝对值	绝对误差	相对误差	Spearman
归一化零输入	0.05	0.004951	0.005035	0.000105	0.0259	0.9762
归一化零输入	0.10	0.010104	0.010071	0.000415	0.0511	0.9524
归一化零输入	0.25	0.025327	0.025177	0.002521	0.1227	0.8810
归一化零输入	0.50	0.052060	0.050354	0.010036	0.2342	0.7810
归一化零输入	1.00	0.105217	0.100707	0.037632	0.4345	0.6095
模糊输入	0.05	0.004384	0.004419	0.000093	0.0241	0.9810
模糊输入	0.10	0.008877	0.008838	0.000364	0.0477	0.9571
模糊输入	0.25	0.021907	0.022095	0.002371	0.1168	0.8905
模糊输入	0.50	0.044622	0.044191	0.008908	0.2244	0.7952
模糊输入	1.00	0.091581	0.088381	0.033841	0.4186	0.6238

四个模型—参照状态组合的样本中位绝对误差均随幅度单调增加，全部 1 600 条图像—参照状态曲线也逐图单调。排序相关随幅度下降。结果支持规定注意力头输出插值中的局部一阶边界：在 $\alpha=0.05$ 时相对误差中位数为 0.0241 – 0.0272，完整替换时为 0.3883 – 0.4345；对应头间相关由 0.9564 – 0.9810 降至 0.6095 – 0.6856。

误差随幅度的变化同时具有绝对和相对意义。绝对误差随真实效应尺度扩大，说明偏差不是固定数值噪声；相对误差从约 2.4% – 2.7% 增至约 38.8% – 43.5%，说明预测误差相对任务效应也在增加。四种模型—参照组合方向一致，降低了结论由某一输入原点或模糊算子单独驱动的可能性。

排序相关下降慢于数值误差增加。即使完整替换时相对误差接近四成，头间 Spearman 仍为 0.61 – 0.69。这一区别对实际使用重要：局部一阶量在大幅替换下不适合精确预测效应大小，但仍保留部分筛选顺序。第 7.4 节因此进一步使用捕获率和遗憾值评价“选哪个头”，而不是只依据逐项误差。

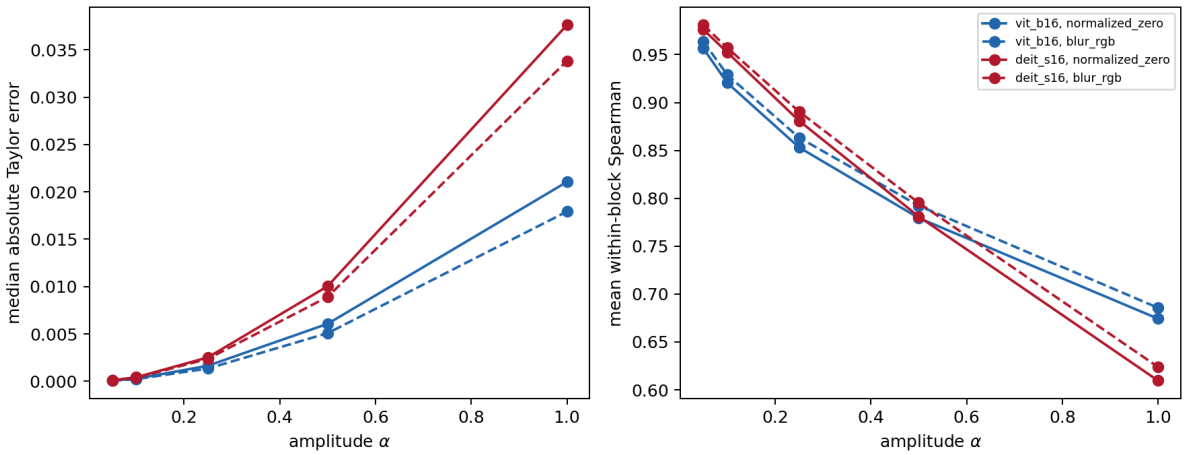


图 7-1 多幅度有限干预。随插值幅度增加，绝对误差和相对误差增加，头间排序相关下降。

7.4 结果：完整成分排序

原确认性成分替换的 12 个模型—参照状态—成分族组合中，11 个满足冻结复合条件；所有成分族联合条件未满足。ViT-B/16 在归一化零参照下的路由/取值相关为 0.0996 [0.0748, 0.1226]，未达到 0.10 点估计门槛；其余 11 组点估计为 0.1065 – 0.3063。结果是“广泛但并非普遍的关联”，相关量级总体处于小到中等范围。

同层注意力头补充比较显示，泰勒估计的 Spearman 为 0.6095 – 0.6856，高于局部图的 0.1476 – 0.2815；泰勒的前 1 项捕获率为 0.8028 – 0.8426，局部图为 0.5075 – 0.5609；泰勒前 1 项遗憾值为 0.0346 – 0.0860，局部图为 0.1163 – 0.2381。显式使用参照位移改善了规定完整替换任务中的头排序。

三种指标对应不同使用方式。Spearman 衡量所有头的全序关系，前 1 项捕获率衡量只执行一个替换时能捕获多少最佳效应，遗憾值衡量所选头与候选最优头的差距。泰勒在三者上同时改善，说明优势不是由某一个相关系数定义造成。跨层残差任务中部分捕获率差为零，也说明这一优势随候选结构和指标改变。

原成分族中 12 个组合有 11 个满足条件，这一结果不能概括为高预测精度。相关中位数仅为 0.0996 – 0.3063，主要支持弱到中等的排序关联；未满足的 ViT-B/16 归一化零参照路由/取值族给出明确例外。正文因此同时报告族计数、点估计、区间和联合决策。

7.5 结果：区域选择

表 7-3 区域替换的绝对效应曲线下面积

模型	参照状态	局部图	区域泰勒	随机	候选上界
ViT-B/16	归一化零输入	0.0309	0.0558	0.0339	0.0654
ViT-B/16	模糊输入	0.0276	0.0518	0.0307	0.0747
DeiT-S/16	归一化零输入	0.0617	0.0961	0.0611	0.1474
DeiT-S/16	模糊输入	0.0395	0.0770	0.0411	0.1063

局部图减区域泰勒的配对中位差依次为 −0.0234、−0.0237、−0.0299 和 −0.0356。局部图减随机的配对中位差依次为 −0.0023、−0.0031、0.0009 和 −0.0010，未显示稳定优势。局部图相对候选上界的归一化遗憾值为 0.5303 – 0.6366，区域泰勒为 0.1442 – 0.3352。四个区域分析族均未满足局部

图相对全部基线提高 0.05 的原复合条件。

绝对曲线下面积相对原目标逻辑值很小：局部图为 0.0031 – 0.0072，区域泰勒为 0.0059 – 0.0107。该尺度说明区域替换在规定预算内只改变目标输出的一部分；候选上界也受 4×4 区域集合和最高 25% 面积限制。归一化遗憾值把方法与同一候选集合的可达上界比较，因此比单独绝对曲线下面积更适合跨模型观察选择效率。

修正后的随机基线先在每次随机重复内对隔离效应取绝对值，再计算曲线下面积，最后平均 20 次重复。这个顺序避免先平均带符号曲线造成正负抵消。修正后局部图相对随机的差值接近零，表明此前看似有利的随机比较主要来自估计器顺序，而不是稳定区域选择能力。

跨层全注意力头补充实验覆盖第 2、5、10 个编码块。完整输入替换的 12 个族中 11 个显著偏向区域泰勒，单头隔离替换的 12 个族全部显著偏向区域泰勒；该补充结果不改变原第 5 块三头确认性决策。

Spatial intervention evaluates a different property

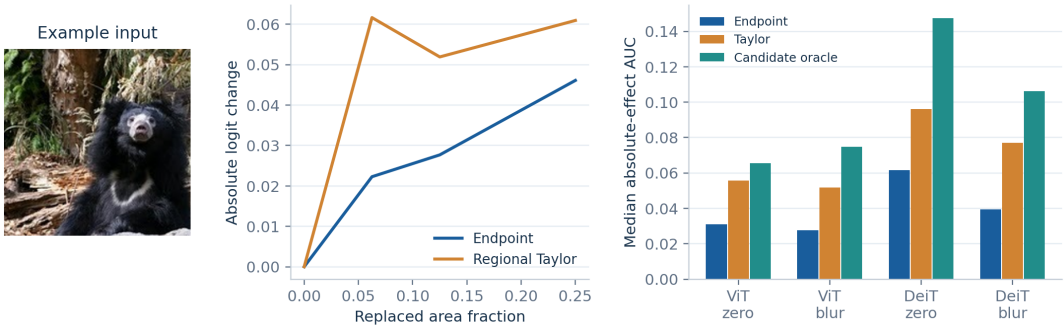


图 7-2 区域干预边界。 左侧为一张图的区域替换曲线，右侧为 400 图的绝对效应曲线下面积分布。

7.6 讨论

多幅度实验和完整替换实验回答两个相邻但不同的问题。前者固定注意力头输出位移方向并改变幅度，建立误差随距离扩大的经验边界；后者比较不同组件或区域在完整替换下的排序。小幅度时较高的头间相关不能推出完整替换时逐项数值准确。

从泰勒展开看，式（5-2）遗漏的是沿位移方向积分时梯度变化产生的高阶余项。多幅度结果直接测量这一余项随距离的经验变化；完整替换结果还叠加不同组件位移尺度和方向的异质性。因而前者更接近局部近似诊断，后者更接近资源约束下的筛选评价。

局部图只依赖当前输入和局部导数，区域泰勒还使用参照状态的实际位移。后者在参照状态已知的替换任务中拥有与任务更匹配的信息。局部图仍可用于描述当前点局部输入结构，但原区域效用复合主张未获支持。

这一结果把方法用途划分为两个场景。若问题是“ 当前目标依赖输入的哪些位置、经过哪些真实边 ”，无需外部参照状态的局部图提供统一结构表示；若问题是“ 把某一变量替换为指定参照状态会造成多大变化 ”，位移感知的泰勒量更接近任务定义。二者的差异来自估计对象，而不是简单的优劣排序。

7.7 本章小结

RQ4 的结论包括三部分。规定插值任务的一阶误差随幅度单调扩大，排序相关同时下降；局部路径图与完整成分效应存在广泛但非普遍的小到中等关联；规定区域替换中，参照状态感知的泰勒估计优于仅用原输入状态的局部图。

第 8 章 综合讨论与结论

8.1 从表示到贡献再到干预

本文的证据链由三个层次构成。表示层由式（3-2）确定：标量 NNS 学习图像是当前点输入乘梯度。贡献层由式（4-4）、式（4-6）和式（4-8）确定：在指定 ViT 图和合法切面上，局部微分可以按查询、键、值、注意力头和残差真实边加和。干预层由式（5-1）至式（5-3）确定：局部一阶量对小位移更准确，其对完整替换的排序效用取决于对象、参照状态和指标。

三层证据解决不同问题。公式恒等式不证明路径分项唯一；结构闭合不证明有限替换效用；一项替换任务上的方法优势也不形成一般解释优越性。把三者分开，使正结果和边界结果可以同时进入结论。

8.2 理论意义

NNS 的雅可比解释消除了逐层传播与自动微分之间的表面差异，并允许用统一输入坐标表示 ViT 异构内部目标。合法切面把“路径”从直观标签变为可检查条件：每条相关微分路径恰好穿越一次。负控制进一步说明，省略恒等旁路或重复加入分支会破坏闭合。

这一理论框架的价值在于可组合性。只要一个内部目标能够写成当前计算图上的标量，式（3-1）就给出输入坐标表示；只要一组真实边构成合法切面，式（4-8）就给出加和关系。新增目标或切面不需要改变基础传播规则，只需明确标量化方式、边集合和闭合检查。

非唯一性反例则规定了理论边界。结构路径不是只由端到端函数决定的规范分解，而是相对于研究者明确给出的图实现、切面和内部坐标。其科学用途在于分析具体实现中的真实边，而不是为等价实现提供不变解释。

因此，路径名称应当理解为模型实现中的操作性坐标。查询、键、值和残差边是标准 ViT 实现中清晰、可干预、可复算的对象；它们适合回答实现机制问题。若未来需要跨架构比较，则应先定义共同切面或把结果聚合到更粗的不变量层级，而不能直接比较同名内部坐标。

8.3 经验意义

五组独立抽样表明，两个固定预训练参数状态中的抽样内部目标随深度依赖更广、更远的输入区域。查询、键和值路径并不共享一个空间轨迹：键和值在两模型中更集中，查询的空间方向随模型而异。路由相对尺度和仅值路径误差随深度提高，说明固定注意力权重的内容传播不能代表深层注意力的完整局部响应。

有限干预给出更直接的边界。小幅头输出插值下，一阶估计具有较低误差和较高头间相关；幅度增大后误差单调上升。完整区域替换中，加入实际参照位移的泰勒估计明显优于原输入局部图。局部微分适合描述当前点附近的结构，参照状态感知的位移估计更适合已指定的有限替换。

方法评价因而需要同时报告“正确计算了什么”和“在什么任务上有用”。本研究的结构闭合结果很强，但区域选择结果为负；这两者并不矛盾。前者说明分项忠实地重构局部微分，后者说明该局部对象在有限区域替换中的信息不足。把负结果保留在主结论中，能够防止读者把数学正确性外推为干预有效性。

8.4 局限性

本文的模型范围是 ViT-B/16 和 DeiT-S/16 各一个固定预训练参数状态。三个随机初始化状态只支持参数状态差异，尚不能识别训练轨迹或多个训练参数状态的一致效应。数据来自确定性选择的 ImageNet 验证图像，类别覆盖优先于同类内变异；结论尚未扩展到其他视觉任务、架构或数据分布。

内部单元结论覆盖五组冻结标记—通道抽样，而不是每个模型的全部单元。错误分类子集仅含 8 张和 14 张图，不能支撑稳定的错误样本分层结论。像素尺度结构还可能受到 16×16 图像块投影和标准化坐标原点影响；本文未执行图像块内置乱或均匀化控制。

有限干预只覆盖两种参照状态、规定的注意力头输出与残差变量、三个主要编码块和最高 25% 区域预算。替换后的混合内部状态不必对应自然图像的完整前向状态。多幅度结果建立的是规定插值方向上的经验一阶边界，不自动推广到任意扰动方向。

8.5 结论

本文得到四项结论。

第一，在精确当前点局部导数且无额外重分配时，标量 NNS 学习图像等于输入乘梯度。该身份确定了基础量及其坐标相关、非函数值完整的边界。

第二，在指定 ViT 计算图与合法切面上，注意力局部微分可以分为查询、键和值路径，残差局部微分可以分为恒等与分支路径；各项加和恢复完整局部输入图。分项依赖图、切面和参数化。

第三，在 ViT-B/16 和 DeiT-S/16 两个固定预训练参数状态中，五组独立抽样均复现内部目标的空间扩展；查询、键和值呈不同总体轨迹；深层注意力的路由相对尺度和仅值路径误差提高，注意力与多层感知机残差呈不同变化。

第四，在规定注意力头输出插值中，一阶误差随幅度单调增加；局部路径图与完整成分效应的关联广泛但并非普遍；给定参照状态的区域替换更适合使用实际位移的泰勒估计。

本文由此将 NNS 扩展为一套面向 ViT 真实计算边的统一实现与系统评价框架。新增价值落在图相对结构分解、可核验实现和边界明确的经验结论。

8.6 本章小结

本章沿“表示—贡献—干预”总结了理论与经验发现，并集中说明模型、抽样、像素结构和替换任务的适用范围。摘要、正文与结论均采用同一主张强度。

参考文献

[1] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16×16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.

[2] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers and distillation through attention[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021, 139: 10347-10357.

[3] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017, 30.

[4] Dou H, Shen F, Zhao J, Mu X. Understanding neural network through neuron level visualization[J]. Neural Networks, 2023, 168: 484-495.

[5] Simonyan K, Vedaldi A, Zisserman A. Deep inside convolutional networks: Visualising image classification models and saliency maps[C]//ICLR Workshop. 2014.

[6] Shrikumar A, Greenside P, Kundaje A. Learning important features through propagating activation differences[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017, 70: 3145-3153.

[7] Sundararajan M, Taly A, Yan Q. Axiomatic attribution for deep networks[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017, 70: 3319-3328.

[8] Dhamdhere K, Sundararajan M, Yan Q. How important is a neuron?[EB/OL]. arXiv:1805.12233, 2018.

[9] Srinivas S, Fleuret F. Full-gradient representation for neural network visualization[C]//Advances in Neural Information Processing Systems. 2019, 32.

[10] Bach S, Binder A, Montavon G, et al. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation[J]. PLoS ONE, 2015, 10(7): e0130140.

[11] Ancona M, Ceolini E, Öztireli C, Gross M. Towards better understanding of gradient-based attribution methods for deep neural networks[C]//International Conference on Learning Representations. 2018.

[12] Smilkov D, Thorat N, Kim B, et al. SmoothGrad: Removing noise by adding noise[EB/OL]. arXiv:1706.03825, 2017.

[13] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 618-626.

[14] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//European Conference on Computer Vision. Springer, 2014: 818-833.

[15] Ribeiro M T, Singh S, Guestrin C. Why should I trust you? Explaining the predictions of any classifier[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 1135-1144.

[16] Lundberg S M, Lee S-I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems. 2017, 30.

[17] Adebayo J, Gilmer J, Muelly M, et al. Sanity checks for saliency maps[C]//Advances in Neural Information Processing Systems. 2018, 31: 9505-9515.

[18] Hooker S, Erhan D, Kindermans P-J, Kim B. A benchmark for interpretability methods in deep neural networks[C]//Advances in Neural Information Processing Systems. 2019, 32.

[19] Sixt L, Granz M, Landgraf T. When explanations lie: Why many modified BP attributions fail[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020, 119: 9046-9057.

[20] Montavon G, Samek W, Müller K-R. Methods for interpreting and understanding deep neural networks[J]. Digital Signal Processing, 2018, 73: 1-15.

[21] Abnar S, Zuidema W. Quantifying attention flow in transformers[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 4190-4197.

[22] Chefer H, Gur S, Wolf L. Transformer interpretability beyond attention visualization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 782-791.

[23] Jain S, Wallace B C. Attention is not explanation[C]//Proceedings of NAACL-HLT. 2019: 3543-3556.

[24] Serrano S, Smith N A. Is attention interpretable?[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 2931-2951.

[25] Kobayashi G, Kuribayashi T, Yokoi S, Inui K. Attention is not only a weight: Analyzing transformers with vector norms[C]//Proceedings of EMNLP. 2020: 7057-7075.

[26] Modarressi A, Fayyaz M, Yaghoobzadeh Y, Pilehvar M T. GlobEnc: Quantifying global token attribution by incorporating the whole encoder layer in Transformers[C]//Proceedings of NAACL-HLT. 2022: 258-271.

[27] Ferrando J, G á llego G I, Tsiamas I, Costa-juss à M R. Measuring the mixing of contextual information in the Transformer[C]//Proceedings of EMNLP. 2022: 8698-8714.

[28] Modarressi A, Fayyaz M, Aghazadeh E, et al. DecompX: Explaining Transformers decisions by propagating token decomposition[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. 2023: 2649-2664.

[29] Achtibat R, Hatefi S M V, Dreyer M, et al. AttnLRP: Attention-aware layer-wise relevance propagation for Transformers[C]//Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024, 235: 135-168.

[30] Mehri F, Soleymani Baghshah M, Pilehvar M T. LibraGrad: Balancing gradient flow for universally better Vision Transformer attributions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2025: 67-78.

[31] Zhang F, Nanda N. Towards best practices of activation patching in language models: Metrics and methods[EB/OL]. arXiv:2309.16042, 2023.

[32] Syed A, Rager C, Conmy A. Attribution patching outperforms automated circuit discovery[EB/OL]. arXiv:2310.10348, 2023.

[33] Kram á r J, Lieberum T, Shah R, Nanda N. AtP*: An efficient and scalable method for localizing LLM behaviour to components[EB/OL]. arXiv:2403.00745, 2024.

[34] Meng K, Bau D, Andonian A, Belinkov Y. Locating and editing factual associations in GPT[C]//Advances in Neural Information Processing Systems. 2022, 35: 17359-17372.

[35] Geva M, Schuster R, Berant J, Levy O. Transformer feed-forward layers are key-value memories[C]//Proceedings of EMNLP. 2021: 5484-5495.

[36] Efron B, Tibshirani R J. An Introduction to the Bootstrap[M]. New York: Chapman & Hall/CRC, 1993.

[37] Holm S. A simple sequentially rejective multiple test procedure[J]. Scandinavian Journal of Statistics, 1979, 6(2): 65-70.